Framework de redacción y validación de papers: fuente de la verdad de Alejandría Magazine

Sep 29, 2026 · @Lou

Abstract

Este documento especifica el método y el marco de validación con que AlejandrIA Magazine genera manuscritos de I+D+i mediante cinco agentes en secuencia: Investigador, Redactor, Revisor, Formateador y Publicador. **Método (Parte I).** Es independiente de la disciplina: un núcleo común de etapas, autoría, uso de IA, referencias y transparencia, y perfiles de reporte por tipo de trabajo: salud (PRISMA, TRIPOD-LLM, STROBE, STARD), ingeniería de software (ACM SIGSOFT Empirical Standards), aprendizaje automático (checklist de NeurIPS), diseño de artefactos (DSRM), desarrollo experimental (criterios de Frascati), innovación (Manual de Oslo y escala TRL) e informe técnico. La ficha de la etapa 1 registra el perfil y la clase de I+D. En el perfil de innovación, un trabajo sin puesta en uso o a disposición de usuarios no se reporta como innovación, y todo nivel TRL se declara con su prueba, entorno y fecha. El método define ocho etapas ordenadas y 16 criterios de validación V01–V16: 14 bloqueantes (V07 y V08 solo en revisiones) y 2 advertencias (V15, V16). Trece criterios se comprueban de forma automática, V02 combina comprobación automática y muestreo, y V10 y V15 requieren juicio de un modelo distinto del redactor más una muestra humana. Cada regla lleva un nivel de evidencia: norma (N), guía de reporte (G), evidencia empírica (E) o decisión de diseño (D). Un manuscrito se publica solo si (1) el Revisor da un puntaje de al menos 80 y no deja bloqueantes de juicio abiertos, con un máximo de 3 vueltas de corrección; (2) una compuerta determinista, aplicada al texto final, no deja bloqueantes abiertos; y (3) un humano lo aprueba de forma explícita. Si tras 3 vueltas siguen abiertos bloqueantes, pasa a revisión humana y no se publica.

Validación (Parte II). Mide tres cosas por separado: consenso de expertos sobre el método y cada perfil, con acuerdo de al menos 80% (calificación de 7 a 9 en una escala de 1 a 9); fiabilidad del validador con defectos sembrados, con cero omisiones en al menos 60 defectos por criterio bloqueante de juicio, falsas alarmas de 10% o menos y kappa de al menos 0,80; y un piloto de 30 manuscritos con tres brazos, 100% de referencias auditadas y detención ante cualquier referencia fabricada que llegue a publicación. La certificación es Certificado, Condicional o No certificado, y se revalida cada enero y ante cambios de modelo, instrucciones o guías. **Herramientas (Parte III).** Son opcionales salvo una línea base: Crossref, OpenAlex, Semantic Scholar, una fuente abierta de retractaciones y LaTeX, más Lean cuando hay demostraciones. **Estado.** Versión 0,1: los umbrales y los perfiles no médicos son decisiones de diseño pendientes de un panel humano, y el marco mide la calidad del reporte y los controles de integridad, no la veracidad de los hallazgos.

Este framework tiene tres partes: la **Parte I (secciones 1 a 11)** fija el método de ocho etapas con que los agentes de Alejandría Magazine redactan un paper, con cada regla acompañada de su fuente y su nivel de evidencia; la **Parte II (secciones 12 a 19)** define

cómo se demuestra que ese método funciona. Es la versión 0.1: necesita validación por un panel humano, y todos los umbrales de la Parte II son propuestas de diseño.

La **Parte III (sección 20)** añade las herramientas externas de verificación (Zotero, scite, Elicit, Wolfram, Lean, LaTeX) y a qué criterios sirve cada una.

1. Alcance y niveles de evidencia

El documento cubre cómo se **redacta y reporta** un artículo científico o técnico de I+D+i dentro de Alejandría Magazine, en cualquier disciplina; no reemplaza la metodología de la investigación en sí (diseño, estadística, ética), que sigue siendo responsabilidad del investigador humano. Cada regla lleva una etiqueta que dice qué tan firme es su respaldo:

Etiqueta	Significado	Cómo se trata
N	Norma o estándar formal de una entidad editorial (ICMJE, COPE, ANSI/NISO)	Obligatoria; el validador la bloquea
G	Guía de reporte por consenso experto (PRISMA, TRIPOD-LLM, EQUATOR)	Obligatoria si el tipo de estudio la exige
E	Evidencia empírica publicada (estudios que miden un fenómeno)	Justifica la regla; se cita el estudio
D	Decisión de diseño de Alejandría, sin respaldo externo directo	Revisable; se marca para el panel de validación

Las reglas **D** existen porque un pipeline de agentes necesita controles que la literatura editorial, pensada para autores humanos, no define. Se distinguen a propósito para que nadie las confunda con un estándar externo.

Núcleo y perfiles (D). El framework se divide en un **núcleo** independiente de la disciplina (etapas, autoría, uso de IA, integridad de referencias, transparencia y los criterios V01 a V16) y **perfiles de reporte** por tipo de trabajo (sección 5). Ninguna regla del núcleo nombra una disciplina: lo específico de un campo, como las guías médicas, vive en su perfil. En la etapa 1 la ficha registra el perfil, y con él se fija qué guía o lista aplica el validador.

2. Principios rectores

Seis principios gobiernan a todos los agentes; las etapas y los criterios de validación de las secciones siguientes se derivan de ellos.

1. **Responsabilidad humana.** Ningún agente es autor: los humanos responden por todo material que haya usado IA, y deben revisar y editar lo generado porque puede ser incorrecto, incompleto o sesgado. *(N: ICMJE 2026 §V.A; COPE)*
2. **Divulgación completa del uso de IA.** Cada uso de un agente o modelo se declara, con la herramienta usada y cómo se usó. *(N: ICMJE 2026 §V.A; COPE)*

3. **Reporte completo y transparente.** El texto debe permitir evaluar, replicar o incluir el estudio en una revisión sistemática; para eso se usan guías de reporte según el diseño. *(G: EQUATOR, PRISMA 2020, TRIPOD-LLM)*
4. **Cada afirmación es trazable a una fuente verificada.** Ninguna referencia entra al manuscrito sin haberse resuelto contra una base bibliográfica. *(E: tasas de citas inventadas por LLM, sección 7; D: protocolo)*
5. **Estructura predecible y modular.** Se usa IMRaD porque permite leer por módulos y evaluar con rapidez, aunque su superioridad no está demostrada frente a alternativas. *(E: Sollaci y Pereira 2004; ver límites en sección 11)*
6. **Separación entre quien produce y quien valida.** El agente que redacta no aprueba su propio texto. *(D)*

3. Método en ocho etapas

Un manuscrito avanza por ocho etapas; ninguna se salta. Corresponden a los cinco agentes de AlejandrIA: Investigador (etapas 1 a 4), Redactor (5), Revisor (6), Formateador (7) y Publicador (8). La etapa 6 puede devolver el trabajo a la 5 hasta que no queden bloqueantes de juicio abiertos, con un máximo de 3 vueltas; si siguen abiertos, el manuscrito pasa al estado "requiere revisión humana" y no se publica. La compuerta de la etapa 8 devuelve el manuscrito al agente responsable del criterio que falle. La secuencia es una decisión de diseño **(D)** que ordena requisitos de fuentes externas, indicadas en la última columna.

#	Etapa	Salida verificable	Agente	Puerta de calidad	Base
1	Definir pregunta, tipo de estudio y guía de reporte aplicable	Ficha del estudio: pregunta, diseño, clase de I+D, guía o perfil elegido	Investigador + autor humano	El autor humano aprueba la ficha	G: EQUATOR
2	Fijar protocolo: objetivos y resultados principales antes de analizar	Protocolo con resultados primarios declarados	Investigador	Los cambios posteriores quedan registrados y justificados	E: cambios de resultados primarios en 40–62% de estudios; G: PRISMA-P
3	Buscar evidencia de forma	Registro de búsqueda:	Investigador	Otra persona podría	G: PRISMA 2020, PRISMA-S

#	Etapa reproducible	Salida verificable	Agente	Puerta de calidad	Base
		bases, cadenas, fecha, criterios		repetir la búsqueda	
4	Extraer y sintetizar	Tablas de evidencia con identificador de fuente por dato	Investigador	Cada dato apunta a una fuente resuelta	D
5	Redactar por secciones IMRaD	Borrador con cada afirmación enlazada a su fuente	Redactor	Cubre los ítems de la guía de reporte elegida	E: IMRaD; G: guía elegida
6	Revisar los criterios de juicio (V02, V10, V15)	Informe del Revisor en JSON: puntaje de 0 a 100 y estado por criterio	Revisor, con un modelo distinto del Redactor	Puntaje de al menos 80 y cero bloqueantes de juicio abiertos; el puntaje solo no decide	D
7	Dar formato y completar metadatos	Manuscrito con referencias en el estilo elegido, contribuciones CRediT, declaración de uso de IA y metadatos FAIR	Formateador	Estructura y metadatos completos; el cuerpo del artículo no cambia	N: ICMJE, COPE, CRediT; G: FAIR

#	Etapa	Salida verificable	Agente	Puerta de calidad	Base
8	Compuerta determinista, aprobación humana y publicación	Informe de la compuerta sobre el texto final, aprobación firmada, versión publicada con corrección y retractación posibles	Publicador + autor humano	Cero bloqueantes deterministas abiertos y aprobación humana explícita	N: ICMJE 2026, COPE; D

Regla de decisión: un manuscrito se publica solo si se cumplen las tres condiciones: (1) el Revisor no deja bloqueantes de juicio abiertos y el puntaje es de al menos 80; (2) la compuerta determinista, aplicada al texto final después del formato, no deja bloqueantes abiertos; (3) un humano lo aprueba de forma explícita. La compuerta va después del formato porque el Formateador reescribe citas y referencias, y lo que se publica es ese texto.

4. Estructura del manuscrito (IMRaD)

Alejandría usa IMRaD (Introducción, Métodos, Resultados y Discusión) como estructura base. Un estudio bibliométrico de 50 años mostró que se adoptó en las revistas médicas desde los años 1940 y se consolidó entre los 1970 y 1980, y que facilita la lectura modular porque cada dato tiene un lugar predecible (Sollaci y Pereira, 2004). El estándar ANSI Z39.16 (1979) lo formalizó en Estados Unidos por un período (CASRAI). Su dominio hoy se explica en buena parte por la exigencia de editores y revisores, no por una comparación experimental con otras estructuras (Habibzadeh, 2026).

Sección	Función	Contenido mínimo	Qué comprueba el validador
Título y resumen	Identificar el tipo de estudio y resumir	El título declara el diseño (p. ej. revisión sistemática); el resumen sigue la lista de resumen de la guía elegida	Título coherente con el diseño; resumen consistente con el cuerpo

Sección	Función	Contenido mínimo	Qué comprueba el validador
Introducción	Justificar la pregunta	Contexto, vacío de conocimiento, objetivo o pregunta	Objetivo idéntico al del protocolo
Métodos	Permitir la replicación	Diseño, fuentes, búsqueda, criterios, análisis, **uso de IA** cuando ayudó a analizar o generar figuras	Ítems de la guía cubiertos; búsqueda reproducible
Resultados	Informar lo hallado sin interpretarlo	Datos, flujo de selección de estudios, resultados de los desenlaces declarados	Todos los resultados primarios del protocolo aparecen
Discusión	Interpretar y limitar	Hallazgos principales, comparación con la literatura, limitaciones	No afirma más de lo que muestran los resultados
Referencias	Sostener las afirmaciones	Lista completa y verificable	Cada referencia resuelta (sección 7)
Declaraciones finales	Transparencia	Contribuciones CRediT, conflictos de interés, financiamiento, uso de IA en redacción, disponibilidad de datos	Presentes y coherentes con el registro del pipeline

El uso de IA para escribir, editar o corregir se declara en los agradecimientos, y el uso para recolectar o analizar datos o crear figuras, en Métodos (Editage, sobre las recomendaciones ICMJE de 2023; COPE pide el mismo detalle de herramienta y uso). Cuando el destino sea una revista concreta, se sigue su instrucción para autores, que puede variar el lugar de la declaración.

IMRaD no es universal (D). IMRaD es la estructura por defecto para trabajo empírico. Otros perfiles usan la suya, y el criterio V03 comprueba la estructura del perfil elegido, no IMRaD en abstracto. Para el diseño de artefactos, el proceso DSRM (Peffers et al., 2007) ofrece seis actividades que pueden estructurar el manuscrito: identificación del problema, objetivos de la solución, diseño y desarrollo, demostración, evaluación y comunicación. Los propios autores sugieren usar la estructura del proceso para estructurar el artículo.

5. Guías de reporte por tipo de trabajo

La red EQUATOR nació para corregir el reporte deficiente de la investigación y reúne guías por diseño de estudio; su meta es que los artículos sean claros, completos y transparentes. La evidencia sobre su efecto es en parte observacional: el uso de PRISMA 2009 se asocia con reportes más completos de revisiones sistemáticas (Page et al., 2021), y EQUATOR sostiene que la exigencia de una guía por parte de la revista mejora la calidad del reporte. Por eso, en Alejandría **el tipo de estudio determina la guía** y la guía determina los ítems que el validador comprueba (etapa 1, ficha del estudio).

Tipo de contenido	Guía aplicable	Notas para el pipeline
Revisión sistemática o metaanálisis	PRISMA 2020: lista de 27 ítems, lista para resumen y diagrama de flujo	Reemplaza a PRISMA 2009; sirve para revisiones originales, actualizadas o continuamente actualizadas; no es una guía para *conducir* la revisión
Protocolo de revisión sistemática	PRISMA-P	Se usa en la etapa 2
Reporte de la búsqueda bibliográfica	PRISMA-S	Se usa en la etapa 3
Estudio que desarrolla, ajusta, diseña prompts o evalúa un LLM	TRIPOD-LLM: 19 ítems principales y 50 subítems, modular, con lista para resúmenes	Guía viva; incluye transparencia, supervisión humana y desempeño por tarea
Modelos de predicción	TRIPOD	Base de TRIPOD-LLM
Estudios observacionales	STROBE	Ver EQUATOR para extensiones
Precisión diagnóstica	STARD	Existe una extensión para IA
Estudios empíricos de ingeniería de software	ACM SIGSOFT Empirical Standards	Son estándares específicos por método, no una lista única: se espera algo distinto de un experimento

Tipo de contenido	Guía aplicable	Notas para el pipeline
		controlado y de un estudio de caso etnográfico. El validador carga el estándar del método declarado
Investigación en aprendizaje automático e IA	Lista de verificación de artículos de NeurIPS (13 temas, más sujetos humanos, aprobación ética y uso de LLM) y lista de reproducibilidad de ML (Pineau et al.)	Cubre afirmaciones, limitaciones, teoría, reproducibilidad, datos y código, significancia estadística, cómputo, impacto, salvaguardas, licencias y documentación de activos; las respuestas «no» se justifican. Es un requisito de un congreso, no un consenso de una red como EQUATOR
Diseño y desarrollo de artefactos: sistemas, métodos, prototipos	Design Science Research, modelo de proceso DSRM (Peffers et al., 2007)	Es un modelo de proceso, no una lista de ítems: el Investigador deriva los ítems de las seis actividades y un humano los aprueba
Investigación aplicada y desarrollo experimental	Criterios de I+D del Manual de Frascati 2015 (OCDE)	Clasifica el trabajo como investigación básica, aplicada o desarrollo experimental y comprueba cinco criterios: novedoso, creativo, incierto, sistemático y transferible o reproducible. No es una guía de reporte: se registra en la ficha
Innovación: producto o proceso nuevo o mejorado, con resultados de uso	Definición de innovación del Manual de Oslo 2018 (OCDE) y escala TRL 1 a 9 de la	No son una guía de reporte: fijan qué se puede llamar innovación y en qué

Tipo de contenido	Guía aplicable	Notas para el pipeline
	Comisión Europea (Horizonte 2020, anexo G)	nivel de madurez está la tecnología. La ficha registra qué es nuevo respecto a qué, si se puso a disposición de usuarios o en uso, y el TRL declarado con su evidencia. Ver reglas debajo de la tabla
Informe técnico sin diseño empírico	Sin guía externa	El Investigador propone la estructura y un humano la aprueba (D)
Otro diseño no listado	Biblioteca EQUATOR (salud) o la norma de la disciplina	El investigador propone la guía y un humano la aprueba

Regla de perfiles (D). Un artículo puede combinar perfiles, como un estudio de aprendizaje automático que además es desarrollo experimental. Los perfiles no médicos de esta tabla se incorporaron a partir de las fuentes indicadas y no se validaron con un panel de cada disciplina; esa validación es parte de la Capa A.

Perfil de innovación (D). El Manual de Oslo 2018 define una innovación como un producto o proceso, o una combinación de ambos, nuevo o mejorado, que difiere de forma significativa de los anteriores de la unidad y que se puso a disposición de usuarios potenciales (producto) o la unidad lo puso en uso (proceso). De ahí salen tres reglas:

1. **Sin uso no hay innovación.** Un prototipo que nadie usó ni tuvo disponible se reporta como desarrollo experimental o diseño de artefacto, no como innovación. El validador comprueba que el manuscrito diga qué es nuevo, respecto a qué, y si se puso a disposición o en uso.
2. **Todo nivel TRL se declara con su evidencia:** la prueba, el entorno y la fecha. El validador rechaza un nivel cuyo entorno no coincide con el que exige la definición de la tabla siguiente.
3. **Se cita la escala usada.** Las definiciones de la UE aplican cuando una convocatoria cita TRL; otras agencias usan variantes, así que el manuscrito indica cuál aplicó.

TRL	Definición de la Comisión Europea
1	Principios básicos observados
2	Concepto de tecnología formulado
3	Prueba de concepto experimental
4	Tecnología validada en laboratorio
5	Tecnología validada en un entorno relevante (industrialmente

TRL	Definición de la Comisión Europea
	relevante en el caso de tecnologías facilitadoras clave)
6	Tecnología demostrada en un entorno relevante (industrialmente relevante en el caso de tecnologías facilitadoras clave)
7	Demostración de un prototipo del sistema en un entorno operativo
8	Sistema completo y cualificado
9	Sistema real probado en un entorno operativo (fabricación competitiva en el caso de tecnologías facilitadoras clave, o en el espacio)

Un artículo puede requerir más de una guía (una revisión sistemática de estudios de LLM combina PRISMA 2020 y TRIPOD-LLM para lo que aplique). Las listas de verificación completas viven en sus publicaciones originales; el agente validador debe cargarlas desde la fuente vigente y registrar su versión, porque varias son guías vivas.

6. Autoría, contribuciones y uso de IA

Esta es la sección más sensible para un enjambre de agentes: las normas editoriales vigentes ubican toda la responsabilidad en personas. El ICMJE incorporó en enero de 2026 una sección nueva (V) sobre IA en la publicación, con partes para autores, revisores y editores, además de una sección sobre el acceso de los autores a los datos.

Lo que exigen las normas (N)

- Se declara al enviar si se usó IA (LLM, chatbots, generadores de imágenes) y se describe cómo, tanto en la carta de presentación como en la sección correspondiente del trabajo (ICMJE §V.A).
- Ninguna herramienta de IA figura como autora, porque no puede responder por la exactitud, integridad y originalidad de la obra (ICMJE §V.A; COPE). Tampoco puede declarar conflictos de interés ni gestionar derechos de autor (COPE).
- Los humanos responden por todo material generado con IA, deben revisarlo y editarlo, y deben poder afirmar que no hay plagio, incluido texto e imágenes producidos por IA (ICMJE §V.A).
- Todo material citado lleva atribución completa, y citar material generado por IA como fuente primaria no es aceptable (ICMJE §V.A).
- No declarar el uso de IA puede exigir correcciones y, en ciertos casos, considerarse mala conducta (ICMJE §V.A).

Cómo se aplica en Alejandría

Elemento	Regla	Base
Autoría	Solo personas; hay un autor responsable humano que aprueba en la etapa 8	N
Registro de uso de agentes	Cada invocación se registra con agente, modelo y versión, tarea y sección afectada; de ese registro se genera la declaración de IA del manuscrito	D, para cumplir N
Contribuciones	Las personas se describen con la taxonomía CRediT (14 roles, ANSI/NISO Z39.104-2022); el trabajo de los agentes se declara aparte, no como rol de autoría	N para CRediT; D para la separación
Ubicación de la declaración	Carta de presentación, agradecimientos o Métodos según el uso: escritura y edición, o análisis y figuras	N; la ubicación exacta depende de la revista destino
Fuentes primarias	El texto de un agente nunca es la fuente de una afirmación	N

Los 14 roles de CRediT son: conceptualización, curación de datos, análisis formal, obtención de financiamiento, investigación, metodología, administración del proyecto, recursos, software, supervisión, validación, visualización, redacción del borrador original y redacción (revisión y edición).

Las mismas reglas fuera de la salud. El ICMJE es una norma biomédica, pero las políticas de ACM e IEEE, del campo de la computación y la ingeniería, coinciden en los tres puntos que sostienen V12 y V13: una IA no puede figurar como autora, el uso de IA generativa debe declararse (por lo general en los agradecimientos) y los autores humanos responden por todo el contenido. ACM pide nombrar la herramienta y qué generó, y no exige declarar correctores ortográficos. Esos datos vienen de resúmenes de segunda mano de CASRAI; conviene contrastarlos con el texto de cada política antes de tratarlos como norma.

Punto abierto para el panel: cuando un agente redacta el borrador y una persona lo revisa, no está definido con claridad si esa persona cumple el rol de redacción del borrador

original o solo el de revisión y edición. Se recomienda que el panel lo resuelva y lo documente aquí.

7. Integridad de las referencias

Un modelo de lenguaje que escribe referencias de memoria produce citas falsas con frecuencia, y por eso Alejandría trata la verificación de referencias como un control bloqueante.

Evidencia (E)

- En un estudio con 300 referencias de neurocuidados generadas por tres LLM sin recuperación de información, el 55,0% tenía alguna inexactitud y el 28,3% era inventada; por modelo, la tasa de invención fue de 8% a 50% (Hallucination Rate of Peer-Reviewed Citations, 2026).
- Un análisis de 100 citas alucinadas en artículos aceptados en NeurIPS 2025 encontró que el 66% eran fabricaciones totales, y propone verificación automática obligatoria al enviar (Ansari, 2026).
- Según una revisión de herramientas de detección, un estudio publicado en The Lancet halló 4.046 citas fabricadas en 2.810 artículos biomédicos, con aumento entre 2023 y 2026, y otro estudio estimó unas 146.932 citas alucinadas en 2025 en cuatro corpus; ninguno prueba que cada caso lo causara un LLM (Detecting Hallucinated and Suspicious Citations, 2026). Se citan aquí de segunda mano; el panel debe confirmarlos en las fuentes originales.
- Una auditoría entre modelos halló tasas más altas al pedir referencias "recientes e influyentes" (74,1%) que "fundacionales" (55,0%), y que las citas reales se repiten entre réplicas mientras las inventadas no (Cross-Model Audit, 2026).

Límite de esta evidencia: los estudios midieron modelos que respondían de memoria. Un pipeline con recuperación de documentos, como el de Alejandría, debería tener tasas menores, pero no hay evidencia propia que lo demuestre; hasta medirlo, se asume el riesgo.

Protocolo de verificación (D)

Nivel	Qué se comprueba	Si falla
1. Origen	Toda referencia entra por recuperación desde una base bibliográfica y trae identificador (DOI, PMID o similar); el redactor nunca crea una referencia de memoria	Bloqueante: se elimina
2. Existencia	El identificador se resuelve en Crossref, OpenAlex o PubMed y	Bloqueante: se corrige desde la base o se elimina

Nivel	Qué se comprueba	Si falla
	coincide en título, autores, año y revista	
3. Soporte	Un agente distinto del redactor verifica que el pasaje citado respalda la afirmación	Bloqueante: se reescribe la afirmación o se cambia la fuente
4. Vigencia	La fuente no figura como retractada ni con expresión de preocupación	Bloqueante si está retractada; advertencia si hay expresión de preocupación
5. Auditoría humana	Un humano revisa una muestra de citas y todas las de afirmaciones centrales	Si se hallan errores, se amplía la muestra

El nivel 3 es el más costoso y el más importante: una referencia real que no dice lo que se le atribuye engaña igual que una inventada, y las comprobaciones de existencia no la detectan.

8. Transparencia y reproducibilidad

Dos problemas documentados justifican estas reglas: el reporte selectivo de resultados y la dificultad de reutilizar datos.

Evidencia (E) y normas (N)

- Un estudio que comparó protocolos y publicaciones de 102 ensayos, con 3.736 resultados en total, halló que entre 40% y 62% de los estudios tenía al menos un resultado primario cambiado, agregado u omitido, y que los resultados significativos se reportaban completos con más frecuencia (según la revisión sobre EQUATOR de *Maturitas*).
- El ICMJE de enero de 2026 añadió una sección sobre el acceso de los autores a los datos y reafirmó el registro prospectivo de ensayos clínicos; también prohíbe acuerdos con patrocinadores que restrinjan el acceso a los datos, el análisis, la elección de revista o el momento de publicar (ICMJE, 2026; Springer, 2026).
- Los principios FAIR (Wilkinson et al., 2016) piden que datos y metadatos sean localizables, accesibles, interoperables y reutilizables, con énfasis en que las máquinas puedan procesarlos; son lineamientos, no un estándar, y “abierto” no equivale a FAIR.

Reglas del pipeline

Regla	Cómo se cumple	Base
Fijar objetivos y resultados principales antes de analizar	Se guarda una copia sellada del protocolo	D, para atender E

Regla	Cómo se cumple	Base
	(etapa 2) con fecha y huella criptográfica	
Reportar toda desviación	Un registro de desviaciones enumera cada cambio de objetivo, método o resultado, con su motivo; el manuscrito lo resume en Métodos	D, para atender E
Declarar disponibilidad de datos y código	Declaración final con enlace a repositorio o motivo de restricción	D; se apoya en el criterio de acceso a datos de ICMJE 2026 §III.L.2
Metadatos legibles por máquina	Identificador persistente, licencia, autores con identificador, procedencia de datos y de agentes	G: FAIR
Trazabilidad completa	Cada figura, tabla y cifra enlaza al paso del pipeline que la produjo	D

No hay evidencia de que estas reglas de trazabilidad mejoren por sí solas la calidad final; se adoptan porque hacen auditable el trabajo de agentes que, de otro modo, sería opaco.

9. Criterios de validación

El agente validador aplica estos 16 criterios en las etapas 6 y 8; un **bloqueante** abierto impide publicar, y una **advertencia** debe quedar atendida o justificada por escrito. EQUATOR presenta la lista de verificación con la página de cada ítem no como un trámite sino como una revisión de completitud, y es lo que este checklist automatiza.

ID	Criterio	Tipo	Verificación	Base
V01	Tipo de estudio, clase de I+D y guía o perfil de reporte registrados en la ficha	Bloqueante	Automática	G
V02	Cada ítem aplicable de la guía o	Bloqueante	Automática y revisión por muestreo	G

ID	Criterio	Tipo	Verificación	Base
	perfil apunta a su ubicación en el texto			
V03	Estructura del perfil completa y en orden (IMRaD por defecto)	Bloqueante	Automática	E
V04	El título identifica el diseño cuando la guía lo pide	Bloqueante	Automática	G (PRISMA 2020, ítem 1)
V05	Objetivos y resultados primarios coinciden con el protocolo o plan de experimento sellado, y toda desviación está registrada	Bloqueante	Automática	D, por E
V06	Todos los resultados primarios declarados aparecen en Resultados	Bloqueante	Automática	D, por E
V07	La búsqueda es reproducible: bases, fechas, cadenas y criterios	Bloqueante en revisiones	Automática	G
V08	Diagrama de flujo de	Bloqueante en revisiones	Automática	G (PRISMA 2020)

ID	Criterio	Tipo	Verificación	Base
	selección de estudios presente			
V09	Toda referencia tiene origen recuperado y existe con metadatos coincidentes	Bloqueante	Automática	D, por E
V10	Cada afirmación citada está respaldada por el pasaje de la fuente	Bloqueante	Agente independiente y muestra humana	D, por E
V11	Ninguna fuente citada está retractada	Bloqueante	Automática	D
V12	Declaración de uso de IA completa: herramienta, versión, tarea y ubicación	Bloqueante	Automática contra el registro de agentes	N
V13	No hay agentes como autores y hay un autor humano responsable	Bloqueante	Automática	N
V14	Contribuciones de las personas en CRediT; conflictos de interés y financiamiento declarados	Bloqueante	Automática	N

ID	Criterio	Tipo	Verificación	Base
V15	Las conclusiones no afirman más que los resultados y la Discusión incluye limitaciones	Advertencia	Agente independiente y revisión humana	D
V16	Declaración de datos y código, y metadatos FAIR completos	Advertencia	Automática	G, D

El ICMJE también exige que los autores puedan afirmar que no hay plagio, incluido el generado por IA; el control de similitud textual queda como un criterio adicional que el panel debe definir (umbral y herramienta), porque la literatura consultada no fija un valor.

Regla de decisión: el manuscrito solo se publica con cero bloqueantes abiertos, tanto de juicio (etapa 6) como deterministas (etapa 8), y con aprobación humana explícita.

10. Responsabilidades por agente

Cada agente tiene un alcance cerrado, y lo que no puede hacer importa tanto como lo que hace, porque de esa separación depende que la validación sea independiente (principio 6). Son los cinco agentes de AlejandrIA. El "validador" que evalúa la Parte II se implementa en dos piezas: el **Revisor**, para los criterios de juicio, y la **compuerta determinista** del Publicador, para el resto. Es una propuesta de diseño **(D)** derivada de las secciones anteriores.

Agente	Hace	No puede	Entrega	Criterios
Investigador	Propone la guía de reporte; fija el protocolo; busca en el RAG (colección del agente y biblioteca compartida), EuropePMC y OpenAlex, y registra la	Escribir texto del manuscrito; introducir referencias de memoria; cambiar resultados primarios sin registro	Ficha del estudio, protocolo sellado, registro de búsqueda, tablas de evidencia	V01, V05, V07, V08

Agente	Hace	No puede	Entrega	Criterios
	búsqueda; extrae y sintetiza con fuente por dato			
Redactor	Redacta cada sección IMRaD con cada afirmación enlazada a una fuente de las tablas de evidencia; resuelve cada comentario del Revisor en el nuevo borrador	Añadir fuentes nuevas; aprobar su propio texto; afirmar más que los resultados	Borrador con afirmaciones trazables	V03, V06, V15
Revisor	Puntúa el borrador de 0 a 100 y evalúa V02, V10 y V15 con un estado por criterio, en JSON, con comentarios concretos	Corregir el manuscrito; usar el mismo modelo que el Redactor; aprobar sin evidencia por criterio	Informe de revisión con puntaje y estado por criterio	V02, V10, V15
Formateador	Reescribe citas y referencias en el estilo elegido; ordena estructura y metadatos; compone las declaraciones de IA, CRediT, conflictos,	Modificar el contenido científico; inventar referencias o declaraciones que no consten en el registro	Manuscrito completo y metadatos FAIR	V04, V12, V14, V16

Agente	Hace	No puede	Entrega	Criterios
	financiamiento y datos a partir de registros			
Publicador (sin LLM)	Aplica la compuerta determinista al texto final: V01, V03 a V09, V11 a V14 y V16; calcula metadatos; publica solo con cero bloqueantes y aprobación humana; gestiona correcciones y retractaciones	Publicar con un bloqueante abierto o sin la firma del autor responsable; usar un modelo de lenguaje	Informe de la compuerta y versión publicada con historial de cambios	Compuerta de la etapa 8
Autor humano	Aprueba la ficha y el manuscrito; asume la responsabilidad del contenido; resuelve advertencias	Delegar en un agente la aprobación final	Aprobación firmada	Principio 1

Cambios propuestos al pipeline actual (D). El pipeline de AlejandrIA ya tiene el orden Investigador, Redactor, Revisor, Formateador, Publicador, con un bucle de hasta 3 vueltas y umbral de 80. Este framework exige cuatro cambios:

1. **Compuerta determinista en el Publicador,** sobre el texto final y después del Formateador.
2. **Salida del Revisor por criterio,** no solo puntaje; un bloqueante abierto impide avanzar aunque el puntaje sea de 80 o más. El Revisor usa un modelo distinto del Redactor y con capacidad suficiente para V10; un modelo muy pequeño solo puede usarse si supera la Capa B.

3. **Aprobación humana obligatoria** antes de publicar, con el control humano que el pipeline ya tiene.
4. **Estado "requiere revisión humana"** cuando tras 3 vueltas siguen abiertos bloqueantes, en lugar de publicar.

El ICMJE dedica una sección a correcciones y control de versiones, y en 2026 recomienda consultar las guías de COPE para retractaciones y expresiones de preocupación; el publicador debe implementarlo como flujo de primera clase, no como excepción.

11. Limitaciones y vacíos de evidencia

Este documento resume normas y estudios consultados el 29 de septiembre de 2026; no es una revisión sistemática y tiene los siguientes límites, que el panel debe cerrar antes de declararlo normativo.

- **IMRaD por convención.** Se sostiene por su uso y por la exigencia editorial, no por una comparación experimental (Habibzadeh, 2026); en humanidades y artes está menos convencionalizado. La sección 4 indica cómo estructurar el diseño de artefactos; falta decidir la estructura de los informes técnicos sin diseño empírico.
- **Cobertura desigual entre disciplinas.** ICMJE, EQUATOR, PRISMA y TRIPOD-LLM nacen de la investigación médica. Para otras disciplinas se incorporaron perfiles de ingeniería de software, aprendizaje automático, diseño de artefactos, desarrollo experimental e innovación (sección 5), pero no se revisaron ciencias sociales, humanidades, economía ni ingenierías físicas, ni las definiciones detalladas de innovación de producto y de proceso del Manual de Oslo, ni escalas de madurez de otras agencias distintas de la UE. Cada perfil nuevo debe validarse con expertos de su campo.
- **Evidencia parcial sobre las guías.** El efecto de las guías de reporte se apoya en estudios observacionales y en la postura de EQUATOR; no se leyó aquí un metaanálisis definitivo.
- **ICMJE §V leído solo en parte.** Se analizó la parte para autores (V.A); las partes para revisores (V.B) y editores (V.C) importan si algún agente participa en revisión por pares y no se incorporaron.
- **Citas de segunda mano.** Las cifras del estudio de *The Lancet* y del estimado de 2025 provienen de una revisión, y los estudios de alucinación midieron modelos sin recuperación de documentos.
- **No cubierto:** evidencia sobre revisión por pares, umbrales de similitud textual, reporte estadístico, aprobación ética y participantes (ICMJE §II.E), preprints, licencias del texto generado por agentes y obligaciones del Reglamento de IA de la UE.

Cómo validar este documento. La Parte II (secciones 12 a 19) define el procedimiento: un panel de expertos valida cada regla por consenso, se mide la fiabilidad del agente validador con manuscritos de prueba y se comprueba el pipeline completo en un piloto. El ICMJE actualiza sus recomendaciones cada año y TRIPOD-LLM es una guía viva, así que el documento se revisa cada enero y cada cambio conserva su versión.

12. Parte II: qué significa “validado”

Un método de redacción no se puede probar “verdadero”; se puede mostrar que expertos lo respaldan, que sus controles detectan fallos y que produce manuscritos que cumplen lo que promete. La Parte II separa esas tres afirmaciones en capas, cada una con su evidencia, y se apoya en los criterios V01 a V16 de la sección 9.

Capa	Pregunta	Cómo se responde	Evidencia que produce
A. Método	¿Las reglas son correctas, completas y viables?	Panel de expertos con consenso estructurado (Delphi)	Informe de consenso por regla, con acuerdo y disensos
B. Validador	¿El agente validador detecta los defectos que debe detectar?	Manuscritos de prueba con errores sembrados y contraste con revisores humanos	Sensibilidad, especificidad y acuerdo por criterio
C. Pipeline	¿El sistema completo entrega manuscritos que cumplen el método?	Piloto de extremo a extremo con línea base humana	Cobertura de la guía, tasa de referencias sin respaldo, tiempo humano

Alcance. Esta parte mide la calidad del reporte y los controles de integridad. No mide si los hallazgos de un paper son ciertos; eso sigue dependiendo del investigador humano y de la revisión por pares posterior.

Orden. Las capas se ejecutan en secuencia: no tiene sentido medir al validador (B) contra reglas que el panel aún no ha aprobado (A), ni ejecutar el piloto (C) con un validador que no ha superado su prueba.

13. Capa A: validación del método por consenso experto

Se usa un Delphi, técnica que reúne el juicio de expertos en rondas anónimas con retroalimentación controlada; es el mismo tipo de proceso con que se desarrolló TRIPOD-LLM (Gallifant et al., 2025), y por eso tiene precedente en el reporte científico.

Lo que dice la evidencia sobre el consenso (E). Una revisión de 100 estudios Delphi encontró que 98 decían evaluar consenso pero solo 72 lo definían, y que la mediana del umbral de acuerdo era 75% (Diamond et al., 2014). Un análisis posterior de 1.904 estudios halló umbrales entre 50% y 100%, con 80% como el más frecuente, y señala que un umbral

alto puede impedir el consenso con una escala de cinco puntos (meta-investigación, 2026). La lección práctica es fijar el criterio **antes** de la primera ronda y registrarlo.

Diseño propuesto (D)

Elemento	Propuesta	Justificación
Panel	12 a 15 personas: metodólogo, editor científico, especialista en integridad de la investigación, estadístico, dos investigadores de disciplinas distintas, ingeniero de agentes, jurista de IA	Cubre las reglas de las secciones 3 a 10; más de una disciplina por el sesgo hacia salud
Conflictos	Declaración escrita de cada panelista; nadie del equipo que construyó los agentes puntúa las reglas de verificación técnica	Evita que se califique el propio trabajo
Qué se puntúa	Por cada regla: pertinencia, verificabilidad por un agente y proporcionalidad de su costo	Separa “es correcta” de “se puede automatizar”
Escala	1 a 9, donde 7 a 9 es acuerdo	Permite matices sin exigir unanimidad
Consenso	Al menos 80% de los panelistas en 7 a 9, fijado antes de la ronda 1; rango intercuartílico como medida de estabilidad	80% es el umbral más frecuente y supera la mediana de 75%
Rondas	Dos o tres; se detiene al lograr consenso o cuando la respuesta se estabiliza	Evita rondas sin fin
Registro	Puntuaciones anónimas, comentarios, cambios de cada regla y motivo	Trazabilidad del documento normativo

Salida de la capa A: una versión 1.0 del método con cada regla marcada como *consensuada*, *consensuada con cambios* o *sin consenso*; las últimas no entran a la lista de bloqueantes hasta resolverse.

14. Capa B: fiabilidad del agente validador

El validador es la pieza que decide si un manuscrito avanza, así que su fiabilidad se mide con manuscritos cuyos defectos ya se conocen, y se compara con expertos humanos.

Lo que dice la evidencia (E)

- Jueces LLM fuertes coinciden con evaluadores humanos en más de 80% de los casos, lo mismo que entre humanos, pero muestran sesgo de posición, de verbosidad y de autopreferencia; los autores recomiendan que el juez sea un modelo distinto del evaluado (Zheng et al., 2023).
- En la verificación de CONSORT, los LLM identificaron bien los ítems cumplidos (F1 mayor a 0,85) pero fallaron en los incumplidos o no aplicables (F1 rara vez sobre 0,40), por lo que los autores los consideran útiles para filtrar pero no para sustituir la evaluación experta (Evaluating the Ability of LLMs to Identify Adherence to CONSORT, 2025). Otros trabajos reportan precisión de 84% a 92% según el conjunto de datos (RAPID, 2025) y variabilidad sustancial entre tres LLM (Detecting CONSORT Compliance, 2025).
- Como referencia humana, en una prueba con 607 revisores del *BMJ* se sembraron 9 errores mayores en cada artículo y en promedio se detectaron unos 3 (Schroter et al., 2008), y el entrenamiento no mejoró de forma sostenida esa cifra.

Tres consecuencias de diseño. Primero, **la exactitud global engaña**: como casi todo ítem está cumplido, un validador que aprueba todo tendría buena exactitud; la métrica principal debe ser la sensibilidad ante defectos. Segundo, **el validador debe ser un modelo distinto del redactor** y no compartir su contexto. Tercero, **superar a un revisor humano promedio es una vara baja**, así que los umbrales de la sección 17 son absolutos.

Métricas por criterio (D, con estadísticos estándar)

Métrica	Qué mide	Uso
Sensibilidad	Proporción de defectos sembrados que el validador detecta	Principal para bloqueantes
Especificidad y tasa de falsas alarmas	Proporción de manuscritos limpios que aprueba sin alertas espurias	Evita bloquear trabajo correcto
Precisión y F1 sobre la clase defecto	Calidad de las alertas emitidas	Comparable con los estudios citados
Kappa de Cohen contra el estándar de oro	Acuerdo más allá del azar	Reporte con intervalo de confianza

Estándar de oro. Dos expertos etiquetan cada manuscrito de prueba de forma independiente y un tercero resuelve los desacuerdos. Antes de usar esas etiquetas, el acuerdo entre los dos primeros debe alcanzar un kappa de al menos 0,80; McHugh (2012) advierte que la lectura clásica de Cohen es demasiado permisiva en salud, y que por debajo de 0,60 los intervalos de confianza son tan anchos que buena parte de los datos puede ser incorrecta.

Cuántos defectos sembrar. Si el validador detecta todos los defectos de un tipo en n intentos, el límite superior del 95% para su tasa de omisión es aproximadamente 3/n (la "regla del tres"). Para asegurar con 95% de confianza una omisión menor a 5%, hacen falta al menos 60 defectos de ese tipo sin ninguna omisión. Esto solo aplica a los criterios que dependen de juicio (V02, V10, V15). Los deterministas (por ejemplo V03, V09, V11, V12, V13) se prueban como código con casos unitarios, sin muestreo estadístico.

15. Conjunto de prueba con errores sembrados

La técnica de sembrar errores conocidos tiene precedente en la evaluación de la revisión por pares (Godlee et al., 1998; Schroter et al., 2008). Aquí se aplica a manuscritos de prueba: cada criterio V01 a V16 tiene defectos definidos, y cada manuscrito base existe en una versión limpia y en versiones con defectos.

Criterio	Defecto sembrado	Tipo de prueba
V01	Ficha sin tipo de estudio o sin guía elegida	Unitaria
V02	Ítems de la guía omitidos (p. ej. criterios de elegibilidad, evaluación del riesgo de sesgo)	Estadística
V03	Falta Métodos, o las secciones están fuera de orden	Unitaria
V04	Título que no declara el diseño cuando la guía lo exige	Unitaria
V05	Objetivo o resultado primario distinto del protocolo sellado, sin registro de desviación	Mixta
V06	Resultado primario del protocolo ausente en Resultados	Mixta

Criterio	Defecto sembrado	Tipo de prueba
V07	Búsqueda sin fechas, cadenas o bases consultadas	Unitaria
V08	Sin diagrama de flujo de selección en una revisión	Unitaria
V09	Referencia inventada por completo, con metadatos parcialmente alterados, con identificador que apunta a otro trabajo, con marcador de posición o solo semánticamente plausible	Unitaria
V10	Referencia real que no respalda la afirmación (incluye casos límite: respalda parcialmente o dice lo contrario)	Estadística
V11	Cita a un artículo retractado	Unitaria
V12	Herramienta, versión o tarea de IA ausente de la declaración pese a constar en el registro	Unitaria
V13	Un agente listado como autor, o ningún autor humano responsable	Unitaria
V14	Falta CRediT, conflictos de interés o financiamiento	Unitaria
V15	Conclusión que afirma más que los resultados; Discusión sin limitaciones	Estadística
V16	Sin declaración de datos y código, o metadatos FAIR incompletos	Unitaria

La taxonomía de V09 (invención total, corrupción parcial de atributos, secuestro de identificador, marcador de posición y alucinación semántica) proviene del análisis de citas fabricadas en NeurIPS 2025 (Ansari, 2026), donde todos los casos analizados fallaban en varios campos a la vez; conviene sembrar también defectos compuestos.

Composición y reglas de uso (D)

- **Diseños variados:** al menos una revisión sistemática, un estudio que evalúa un LLM, un estudio observacional y un diseño no biomédico, en los idiomas en que publica la plataforma.
- **Controles limpios:** al menos la mitad de las versiones no tiene defectos, para medir falsas alarmas.
- **Ciego:** el validador no ve las etiquetas ni la lista de defectos sembrados.
- **Conjunto reservado:** un subconjunto no se usa nunca para ajustar el validador ni sus instrucciones; solo para la decisión de aceptación.
- **Defectos realistas:** los manuscritos base salen de borradores inéditos del propio pipeline o de artículos con licencia abierta modificados a fondo (ver contaminación de datos en la sección 19), no de texto sintético trivial.
- **Reposición:** cuando cambie el validador o el método, se renuevan los casos para que no se memoricen.

16. Capa C: piloto de extremo a extremo

El piloto comprueba si el pipeline completo, con sus agentes y su validador ya certificado, produce manuscritos que cumplen el método. Se registra su protocolo antes de empezar, con las métricas primarias y el plan de análisis, por la misma razón por la que el método exige fijar los resultados principales de un estudio: el cambio de resultados primarios tras ver los datos es frecuente y sesga la conclusión (sección 8).

Brazos comparados (D)

Brazo	Qué es	Qué permite concluir
1. Pipeline completo	Investigador, redactor, formateador, validador y aprobación humana	Desempeño del sistema como se usará
2. Pipeline sin validador	El mismo flujo, saltando la revisión y la compuerta de validación (etapas 6 y 8)	Cuánto aporta el validador; sin este brazo no se puede atribuirle mérito
3. Línea base humana	Manuscritos equivalentes redactados por investigadores sin el pipeline	Punto de comparación de calidad y tiempo

Evaluadores expertos, ciegos al brazo, puntúan todos los manuscritos con el mismo checklist V01 a V16 y la guía de reporte elegida. En el piloto se audita el **100%** de las referencias contra las bases bibliográficas: muestrear falsearía la medida principal.

Métricas primarias

- **Cobertura de la guía:** porcentaje de ítems aplicables cubiertos, por manuscrito.
- **Escapes:** defectos bloqueantes que la auditoría experta halla en un manuscrito que el validador ya había aprobado; se reportan como cantidad por manuscrito y por criterio.
- **Referencias sin respaldo o inexistentes** que llegan a la etapa 8.
- **Consistencia de la declaración de IA** con el registro de agentes.

Métricas secundarias: ciclos entre redactor y validador, tiempo humano por manuscrito, costo por manuscrito y valoración de los autores humanos.

Tamaño. Un piloto de 30 manuscritos (10 por diseño) sirve para detectar problemas grandes, no para demostrar tasas bajas: sin ningún escape en 30 manuscritos, el límite superior del 95% para la tasa de escapes es cercano a 10% (regla del tres). Por eso el piloto se ve como paso previo, y la certificación estadística la da la capa B.

Regla de parada. Un solo escape de una referencia inventada detiene el piloto, exige análisis de causa raíz y repetir la capa B para ese criterio antes de continuar.

17. Criterios de aceptación

Los umbrales son propuestas de diseño **(D)**: la literatura consultada respalda las métricas y algunas cifras de referencia (75% a 80% en consenso Delphi, kappa de 0,80, la regla del tres), pero no fija cuánto error tolera un pipeline editorial. Son la parte que el panel debe decidir, y se fijan antes de ejecutar las pruebas.

Capa	Métrica	Umbral propuesto	Si no se cumple
A	Consenso por regla	Al menos 80% de los panelistas en 7 a 9	La regla pasa a “sin consenso” y no es bloqueante hasta resolverse
A	Participación	Al menos 75% del panel responde cada ronda	Se reclutan reemplazos y se repite la ronda
B	Casos unitarios de criterios deterministas	100% superados	Se corrige el código y se repite

Capa	Métrica	Umbral propuesto	Si no se cumple
B	Sensibilidad en criterios de juicio bloqueantes (V02, V10)	Cero omisiones en al menos 60 defectos por criterio (omisión menor a 5% con 95% de confianza)	El criterio pasa a revisión humana completa
B	Sensibilidad en criterios de juicio de advertencia (V15)	Al menos 80%	Se mantiene como advertencia con revisión humana
B	Falsas alarmas	No más de 10% de las versiones limpias con alerta espuria, por criterio	Se ajusta el criterio y se repite con casos nuevos
B	Kappa contra el estándar de oro	Al menos 0,80 (con intervalo de confianza)	Igual que sensibilidad
B	Kappa entre los dos expertos que etiquetan	Al menos 0,80, antes de usar las etiquetas	Se afina la guía de etiquetado y se reetiquetan
C	Referencias inventadas que llegan a la etapa 8	Cero	Regla de parada del piloto
C	Cobertura de la guía	Al menos 90% y no menor que la línea base humana	Se investiga qué ítems se omiten y se corrige el redactor
C	Escapes de bloqueantes	Menos en el brazo 1 que en el brazo 2	Sin ventaja demostrada, el validador no se declara eficaz
C	Tiempo humano	Sin umbral; se informa junto con la línea base	Informativo para decidir el despliegue

Decisión de certificación (D), por versión del método, del validador y de los modelos:

1. **Certificado:** capa A consensuada, capa B superada en todos los criterios bloqueantes y capa C sin reglas de parada.
2. **Condicional:** fallan criterios de juicio en B; el pipeline puede operar solo con revisión humana completa de esos criterios, y se consigna en cada manuscrito.
3. **No certificado:** falla cualquier criterio determinista o un escape de referencia inventada; no se publica con el pipeline.

18. Gobernanza y revalidación

Una certificación vale para una combinación concreta de método, validador, modelos e instrucciones, y caduca cuando cualquiera cambia. Hay dos razones de fondo: las fuentes externas cambian (el ICMJE revisa sus recomendaciones cada año, TRIPOD-LLM es una guía viva y PRISMA 2020 reemplazó a PRISMA 2009), y los modelos también cambian, con desempeño distinto entre versiones y entre proveedores en tareas de verificación de guías (estudios de la sección 14). TRIPOD-LLM incluye un ítem específico para reportar las actualizaciones del modelo y su desempeño posterior, y aquí se aplica al propio pipeline.

Disparador	Qué se revalida	Plazo propuesto
Cambio de versión del modelo del validador o del redactor	Capa B completa en criterios de juicio; casos unitarios de los deterministas	Antes de volver a operar
Cambio de instrucciones o de herramientas del validador	Capa B en los criterios afectados	Antes de volver a operar
Actualización de ICMJE, COPE, PRISMA, TRIPOD-LLM u otra guía en uso	Capa A breve sobre las reglas afectadas; luego capa B si cambia un criterio	En el mes siguiente a la publicación
Nuevo tipo de estudio o disciplina	Capas A y B para ese tipo; piloto pequeño	Antes de aceptar manuscritos de ese tipo
Defecto hallado tras la publicación	Análisis de causa raíz; el caso entra al conjunto de prueba; capa B del criterio	Al detectarse
Calendario	Recertificación completa	Cada 12 meses, en enero, siguiendo el ciclo del ICMJE

Expediente de validación (D). Cada certificación deja un expediente versionado con el protocolo, los manuscritos de prueba, los resultados por criterio con intervalos de confianza, la decisión, los firmantes y las versiones exactas de modelos e instrucciones. Sin él, no hay forma de auditar por qué un manuscrito se publicó.

Independencia. El comité que certifica no debe depender del equipo que construye los agentes, porque el principio de separación entre quien produce y quien valida (principio 6 de la sección 2) se aplica también al propio sistema. Las correcciones y retractaciones de artículos ya publicados se manejan con las guías de COPE, y sus causas alimentan el conjunto de prueba.

19. Limitaciones de la validación y decisiones abiertas

Limitaciones de la evidencia y del diseño

- **Evidencia sobre validadores LLM concentrada en CONSORT.** Casi todos los estudios de verificación automática de guías se hicieron sobre ensayos clínicos y en inglés; no hay datos consultados para PRISMA 2020, TRIPOD-LLM ni para manuscritos en español o de humanidades.
- **Varios estudios son preprints.** Las evaluaciones de CONSORT en medRxiv y arXiv y la auditoría entre modelos en arXiv no habían pasado revisión por pares al consultarse; se usan como indicios, no como prueba.
- **La línea base humana es antigua.** La cifra de 3 errores detectados de 9 viene de ensayos revisados por el *BMJ* en 2008, y no equivale a la calidad de revisión actual.
- **Contaminación de datos.** Si los manuscritos de prueba son artículos públicos, un modelo puede haberlos visto durante su entrenamiento; conviene usar borradores inéditos o versiones fuertemente modificadas.
- **La regla del tres supone defectos independientes.** Varios defectos dentro de un mismo manuscrito no lo son del todo, así que el tamaño efectivo de la muestra es menor y el panel puede pedir más manuscritos.
- **Costo.** Etiquetar con dos expertos y un tercero, auditar el 100% de las referencias y correr tres brazos tiene un costo significativo que este documento no estima.
- **Alcance.** No se evalúa la verdad de los hallazgos, ni obligaciones legales como el Reglamento de IA de la UE.

Decisiones que debe tomar el panel

Decisión	Opciones	Efecto
Umbrales de la sección 17	Aceptarlos o subir o bajar cada uno	Define cuánto error tolera la plataforma
Tolerancia a falsas alarmas	10% por criterio u otro valor	Un validador muy estricto bloquea trabajo correcto y erosiona la confianza
Composición del panel y del comité de certificación	Roles de la sección 13 u otros	Independencia y cobertura disciplinar
Idiomas y disciplinas del conjunto de prueba	Solo los actuales o también los previstos	Determina dónde vale la certificación
Tamaño del piloto	30 manuscritos u otro	Precisión frente a costo

Decisión	Opciones	Efecto
Umbral de similitud textual	Herramienta y valor	Pendiente desde la sección 9

20. Parte III: herramientas externas de verificación

Para que el paper sea lo más confiable posible, los agentes no deben verificarse a sí mismos: cada comprobación crítica se apoya en una herramienta externa cuyo resultado queda registrado. Esta parte asigna cada herramienta a los criterios V01–V16 y a un agente, e indica **qué verifica y qué no**. Todo lo de esta sección es una decisión de diseño **(D)**; los límites de cada herramienta vienen de sus fuentes (ver Referencias).

Principio. Una herramienta aporta evidencia, no un veredicto. Su salida es una señal que el validador registra y que un humano puede auditar.

Herramienta	Criterios	Agente	Qué verifica	Límite documentado
Zotero (con avisos de Retraction Watch) (opcional)	V09, V11	Formateador y validador	Biblioteca única de referencias con metadatos; marca los artículos retractados y avisa al citarlos. El conector del catálogo permite buscar papers y añadir citas desde Zotero	Los avisos solo funcionan con ítems que tienen DOI o PMID y cubren cerca de tres cuartos de los datos de Retraction Watch. Falta confirmar si el conector expone esos avisos o solo los muestra el cliente de Zotero. Lo que no tiene identificador queda como no verificado
Crossref, OpenAlex y Semantic Scholar	V09	Validador	Existencia de cada referencia y coincidencia de título,	Verifican que el trabajo existe, no que respalde

Herramienta	Criterios	Agente	Qué verifica	Límite documentado
			autores, año y DOI	la afirmación (eso es V10)
Google Scholar	Ninguno automático	Solo humano	Búsqueda manual complementaria	No tiene API oficial y sus términos prohíben el acceso automatizado; los agentes no lo consultan. Para automatizar se usan las tres fuentes de la fila anterior
Scite (conector) (opcional)	V10, V11	Validador	El conector del registro expone una herramienta de búsqueda de literatura con respuestas basadas en investigación. El servicio clasifica cómo cita cada trabajo posterior (apoya, contrasta o menciona)	Falta comprobar si el conector devuelve esa clasificación o solo resultados de búsqueda. Es una señal de contexto, no el pasaje exacto que respalda tu afirmación: V10 mantiene la comprobación del pasaje y la muestra humana
Elicit (conector o API) (opcional)	Etapas 3 y 4, V07, V08	Investigador	Búsqueda, cribado de resúmenes y textos completos, y	El plan Pro limita cada búsqueda a 300 resultados y

Herramienta	Criterios	Agente	Qué verifica	Límite documentado
			extracción en tabla. La API exige plan Pro o superior	20 columnas de extracción por revisión, con 100 solicitudes por minuto. Su extracción es un candidato: cada dato conserva su fuente y se audita una muestra
Wiley Scholar Gateway (conector) (opcional)	V09, V10	Investigador y validador	Búsqueda semántica de literatura académica con citas	Cubre lo que la editorial indexa; no reemplaza a Crossref para comprobar existencia
Consensus (conector) (opcional)	Etapa 3, V07	Investigador	Segunda fuente de búsqueda de investigación científica, para contrastar la cobertura	No sustituye la búsqueda reproducible con cadenas y fechas que exige V07
Scholar Sidekick (opcional)	V09, V10	Validador	Según su descripción en el catálogo: auditar, verificar y citar papers	Sus funciones reales están sin verificar. Es candidato a entrar en la prueba de la Capa B antes de usarse
Self Plagiarism	Sin criterio actual	Validador	Compara un texto pegado con otro para	Solo compara los textos que se

Herramienta	Criterios	Agente	Qué verifica	Límite documentado
Checker (opcional)			detectar reutilización	le entregan, no busca en la web. Detecta reutilización propia, y V01–V16 no cubre plagio: ver decisiones abiertas
Academic Writing Toolkit (opcional)	V15	Validador	Según su descripción: revisa borradores académicos	Es la revisión de otro modelo, no una comprobación independiente. Se trata como señal, nunca como aprobación de V15
Wolfram Alpha (opcional)	Cifras y ecuaciones del manuscrito	Validador	Recalcula de forma independiente cada cálculo, ecuación y valor derivado que el redactor declare	Comprueba el cálculo, no que la ecuación elegida sea la correcta para el problema
Lean 4 con Mathlib	Teoremas y demostraciones	Validador	El núcleo de Lean acepta o rechaza una demostración formal	Solo aplica a lo formalizable. Acepta la prueba de lo que se escribió en Lean, pero no garantiza

Herramienta	Criterios	Agente	Qué verifica	Límite documentado
LaTeX con plantilla IEEE (IEEEtran) y BibTeX	V03, V16	Formateador	Compilación reproducible del manuscrito con plantilla, bibliografía y metadatos generados desde Zotero	El formato IEEE es un estilo editorial, no una prueba de calidad científica. Es habitual en ingeniería y computación; en ciencias de la vida cada revista pide el suyo
Life Sciences NGS Analysis (opcional)	V05, V06, V16	Investigador y validador	Según su descripción en el catálogo: enrutamiento guiado de análisis NGS y ejecución local. Uso previsto: pipelines reproducibles con versiones fijas, datos de entrada con su acceso y re-ejecución por el validador	Sus funciones concretas están sin verificar. Debe probarse con un conjunto de datos de referencia y sus versiones quedan fijadas en el expediente

Herramientas opcionales para investigar (D). Las marcadas *(opcional)* son ayudas: amplían la búsqueda, el cribado y las comprobaciones, pero el pipeline no depende de ellas. La línea base obligatoria es Crossref, OpenAlex y Semantic Scholar para V09, una fuente abierta de retractaciones para V11, la compilación de LaTeX y Lean cuando el paper tenga demostraciones.

1. **Ningún criterio bloqueante se aprueba solo con una herramienta opcional.** Lo que una opcional encuentra entra como candidato, con su fuente, y se verifica contra la línea base antes de citarse.
2. **Si una opcional no está disponible, el pipeline sigue** con la línea base y el expediente lo registra. Esto no contradice la regla de falla cerrada: esa aplica cuando falla la línea base.
3. **Cifras y ecuaciones sin Wolfram** pasan a revisión humana.
4. **Una opcional pasa a obligatoria** solo después de superar la prueba de la Capa B.

Reglas de integración (D).

1. **Registro.** Cada llamada a una herramienta deja en el expediente de validación la herramienta, versión, fecha, consulta y resultado.
2. **Determinista primero.** Se aplican antes las comprobaciones sin juicio de modelo (Crossref, Zotero, Wolfram, Lean, compilación LaTeX) y después las que requieren juicio (V10, V15).
3. **Señal no es veredicto.** Las salidas de scite y Elicit orientan la revisión; no aprueban un criterio por sí solas.
4. **Falla cerrada.** Si una herramienta no está disponible o no cubre un ítem (por ejemplo, una referencia sin DOI), el estado es no verificado y el criterio bloqueante no se aprueba.
5. **Lean sin atajos.** Se rechaza toda demostración que contenga `sorry`, `admit` o axiomas adicionales a los estándar. Un estudio de 2026 sobre autoformalización en Lean halló que los modelos recurren a `sorry` o `admit` en cerca de 13% de los fallos y citan lemas de Mathlib inexistentes en cerca de 8%; por eso el resultado lo decide el compilador de Lean y no el modelo.
6. **Las herramientas entran a la Capa B.** El conjunto de prueba del capítulo 15 debe incluir defectos de cada herramienta: una cita a un artículo retractado, una ecuación con un número alterado, una demostración con `sorry` y una referencia con DOI de otro trabajo. La herramienta se considera confiable cuando detecta esos defectos.
7. **Privacidad y licencias.** Antes de enviar un manuscrito no publicado a un servicio externo, se revisan sus condiciones de uso y de retención de datos.

Decisiones abiertas de esta parte.

- Qué plan de Elicit y qué acceso a scite (API o conector) contrata la CCHIA, y cuáles de estas herramientas se conectan al swarm. En esta sesión de Claude ninguna de ellas está conectada.
- Life Sciences NGS Analysis es la herramienta identificada para NGS; falta probar qué hace realmente con datos de referencia.

- Si IEEE es el estilo único o se elige por tipo de estudio.
- Qué tipos de artículo tienen contenido formalizable en Lean; para el resto, Wolfram y la revisión humana son el techo.
- Si se añade un criterio de reutilización de texto y plagio (COPE lo trata como mala conducta) con Self Plagiarism Checker u otra herramienta; hoy V01–V16 no lo cubre.
- Cuáles de las herramientas con funciones sin verificar (Scholar Sidekick, Academic Writing Toolkit, NGS, conector de scite) pasan la prueba de la Capa B.

Límite general. Estas herramientas reducen el riesgo de error, pero no lo eliminan: no existe una interpretación absoluta que garantice que un paper sea correcto. Por eso la aprobación final sigue siendo humana (etapa 8).

21. Referencias

Fuentes primarias abiertas y leídas para este documento

- ICMJE. Up-dated ICMJE Recommendations, January 2026.
- ICMJE. Recommendations, Section V.A: Use of AI by Authors.
- ACM SIGSOFT. Empirical Standards. Estándares de evidencia específicos por método para ingeniería de software.
- NeurIPS. Paper Checklist Guidelines. Lista de verificación de artículos.
- Pineau J. et al. Improving Reproducibility in Machine Learning Research. JMLR, 2021. Leído solo el resumen.
- OCDE. Frascati Manual 2015, capítulo 2: definiciones. Definición de I+D y cinco criterios.
- Peffers K., Tuunanen T., Rothenberger M., Chatterjee S. A Design Science Research Methodology for Information Systems Research. Journal of Management Information Systems 24(3):45–77, 2007.
- OCDE. Oslo Manual 2018. Definición general de innovación; no se pudieron leer las definiciones detalladas de innovación de producto y de proceso.
- Comisión Europea. Horizon 2020 Work Programme 2014-2015, anexo G: Technology readiness levels (TRL). Escala de nueve niveles.

Fuentes consultadas por extracto de búsqueda (confirmar en el original antes de citar como norma)

- Page MJ et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. BMJ, 2021.
- Gallifant J et al. The TRIPOD-LLM reporting guideline for studies using large language models. Nature Medicine 31:60–69, 2025.
- Sollaci LB, Pereira MG. The IMRAD structure: a fifty-year survey. J Med Libr Assoc 92:364–367, 2004; resumida en CASRAI, IMRaD Structure.
- Habibzadeh F. Conclusion First: A Modest Proposal to Reorganize the IMRaD Structure. Learned Publishing, 2026.
- COPE. Authorship and AI tools: position statement.

- NISO. ANSI/NISO Z39.104-2022, CRediT Contributor Roles Taxonomy y credit.niso.org.
- EQUATOR Network. Reporting guidelines and journals: fact and fiction y guías para revisiones sistemáticas.
- The EQUATOR Network and reporting guidelines. Maturitas.
- Hallucination Rate of Peer-Reviewed Citations Generated by Large Language Models in Neurocritical Care, 2026.
- Ansari S. Compound Deception in Elite Peer Review: fabricated citations at NeurIPS 2025, 2026.
- Detecting Hallucinated and Suspicious Citations: What Current Tools Can and Cannot Do, 2026.
- How LLMs Cite and Why It Matters: A Cross-Model Audit, 2026.
- Wilkinson MD et al. The FAIR Guiding Principles for scientific data management and stewardship. Scientific Data 3:160018, 2016.
- ICMJE Recommendations (2026) on the Use of AI in Scientific Writing, 2026.
- Editage. The ICMJE recommendations on AI: advice for authors and peer reviewers.
- Enago. ICMJE 2026 revised recommendations: key changes.

Fuentes adicionales de la Parte II, consultadas por extracto de búsqueda

- Diamond IR et al. Defining consensus: a systematic review recommends methodologic criteria for reporting of Delphi studies. J Clin Epidemiol 67:401–409, 2014.
- Sample size and consensus methods used in Delphi studies are heterogeneous: meta-research study, 2026.
- Zheng L, Chiang W-L, Stoica I et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena, 2023.
- Evaluating the Ability of Large Language Models to Identify Adherence to CONSORT Reporting Guidelines in Randomized Controlled Trials, preprint, 2025.
- Large Language Models for Detecting CONSORT Guideline Compliance in Published Randomized Clinical Trials, preprint, 2025.
- RAPID: Reliable and efficient Automatic generation of submission rePortIng checklists with large language moDels, 2025.
- Schroter S et al. What errors do peer reviewers detect, and does training improve their ability to detect them? 2008; resumido en Effective Peer Review: Who, Where, or What?.
- Godlee F, Gale CR, Martyn CN. Effect on the quality of peer review of blinding reviewers and asking them to sign their reports. JAMA, 1998.
- McHugh ML. Interrater reliability: the kappa statistic. Biochemia Medica 22(3):276–282, 2012.
- Zotero. Retracted item notifications with Retraction Watch integration. Blog de Zotero.
- Elicit. Elicit API Reference. Documentación de la API: búsqueda, informes, revisiones sistemáticas, planes y límites.

- CASRAI. Google Scholar API: There Is No Official One. Estado de la API y términos de acceso automatizado.
- Evaluation of LLMs for Mathematical Formalization in Lean. arXiv 2606.05632, 2026.
- scite: A smart citation index that displays the context of citations. Quantitative Science Studies, 2021. Consultada solo por resultado de búsqueda; la página de la API de scite no pudo leerse.
- CASRAI. ACM Policy on Authorship: Defined. Resumen de segunda mano de la política de ACM sobre autoría e IA generativa.
- CASRAI. IEEE Generative AI Policy: Author Disclosure Rules. Resumen de segunda mano de la política de IEEE.